Rapport SAé - Administration des Données

I - Introduction

Dans le cadre de la SAé, nous avons étudié un jeu de données portant sur 5 000 utilisateurs d'un réseau social, décrit par 39 variables de trois types : **qualitatives** (gender, region, subscription, device_type), **quantitatives** (nb_sessions, time_on_platform, nb_friends, etc.) et **dérivées** (engagement_score, churn_risk).

Nous avons analysé ce dataset dans le contexte d'un réseau social : les valeurs élevées de likes ou de messages ne sont donc pas traitées comme des erreurs, mais comme le reflet de profils "Power Users". Les durées sont exprimées en **minutes**.

L'objectif de ce rapport est d'une part, détailler la méthodologie de nettoyage et de préparation des données réalisée avec la bibliothèque Python Pandas, et d'autre part, présenter une analyse exploratoire à travers des visualisations qui croisent les différentes variables afin de mettre en évidence les tendances et les relations significatives au sein du dataset.

II - Nettoyage et compréhension des données

Le dataset présentait initialement plusieurs défauts nécessitant un nettoyage préalable via Pandas :

- **Anomalies de l'âge :** Présence d'individus de 400 voire 550 ans, qui sont des multiples de 10 avec un zéro supplémentaire saisi par erreur (ex : 40 ans → 400 ans x_x).
- **Caractères spéciaux :** Symboles parasites dans les colonnes numériques (**###** dans les likes) et régions marquées **???**.
- **Valeurs négatives :** Certaines variables comme les messages ou les likes présentaient des valeurs négatives, ce qui est impossibles dans ce contexte.
- **Données manquantes :** Les NaN ont été conservés pour ne pas fausser les statistiques.

L'observation globale révèle une forte hétérogénéité des comportements. Une minorité de "Power Users" génère la majorité des interactions et tire les moyennes vers le haut, tandis que la masse des utilisateurs reste passive. On note aussi que certains utilisateurs très actifs déclarent une satisfaction faible (1/5), ce qui montre que l'usage intensif n'est pas toujours synonyme de plaisir.

Observation personnelle : Les sessions sur *tablette* sont nettement plus longues que sur *mobile*, ce qui semble réservé aux interactions rapides. La tablette favorise une consommation de contenu prolongée.

III - Visualisations et analyse approfondie

1. Diagramme en barres de la distribution des âges en Europe et en Asie

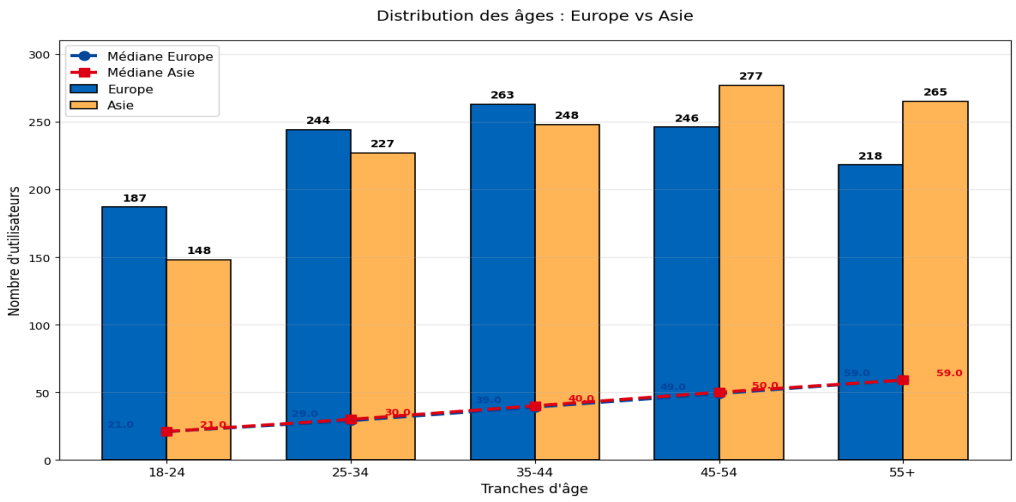

Ce graphique compare la répartition des âges entre les utilisateurs européens et asiatiques, découpée en cinq tranches d'âge. On a choisi de comparer ces deux régions car ce sont les deux plus représentées du dataset, et elles incarnent deux réalités numériques souvent opposées (marché établi vs marché en pleine expansion), ce qui rend leur comparaison plus pertinente qu'avec l'Afrique ou l'Amérique, dont les effectifs sont plus faibles. Les deux distributions se ressemblent beaucoup. Les fréquences relatives sont quasi-identiques classe par classe, sans qu'une tranche d'âge ne se démarque vraiment.

En revanche, si l'on s'intéresse aux effectifs cumulés, des différences apparaissent. En cumulant les classes **18-44 ans**, on constate que cette population représente la majorité des utilisateurs européens. L'Europe est donc un marché porté par les tranches d'âge inférieures à la médiane globale. À l'inverse, en cumulant les 45 ans et plus, c'est l'Asie qui domine nettement. La distribution y est décalée vers les valeurs supérieures, avec une médiane plus élevée, ce qui traduit une population d'utilisateurs plus âgée.

Dans un contexte réel, ces résultats suggèrent que le réseau social n'est pas utilisé de la même façon selon les régions. En Asie, une part plus importante des utilisateurs est senior, ce qui veut dire que leurs habitudes, leur temps passé et leur type de contenu consommé sont probablement très différents de ceux des jeunes européens. Un réseau social qui ignore cette réalité risque de proposer une expérience inadaptée à une grosse partie de ses utilisateurs.

2. Nuage de points représentant le risque d'abandon en fonction du score d'engagement

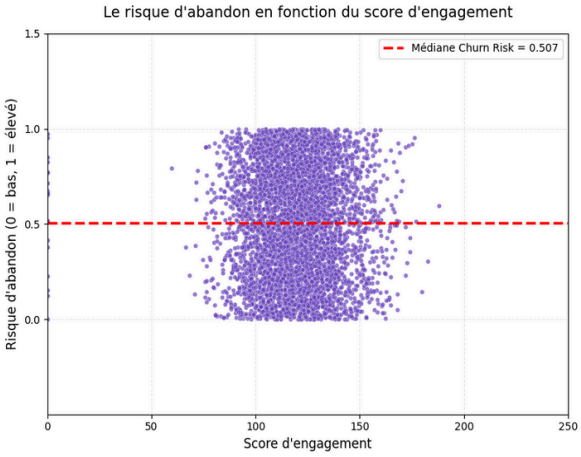

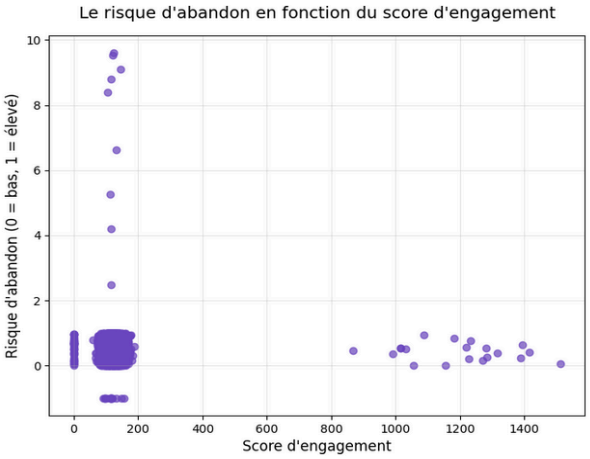

Contrairement à nos analyses démographiques qui nécessitaient une segmentation par marché, nous avons choisi ici d'étudier l'intégralité de notre base de données, toutes régions confondues. Afin d'évaluer l'engagement des utilisateurs de la plateforme, nous avons tenté de vérifier l'hypothèse suivante : un utilisateur très engagé est-il systématiquement un utilisateur fidélisé ? Pour cela, nous avons croisé le score d'engagement global de chaque abonné avec son risque d'abandon prédit (de 0 à 1).

Pour mener à bien cette analyse, nous avons procédé en deux temps : une vue macroscopique globale (Graphique de droite), suivie d'une vue ciblée sur le cœur de notre base d'utilisateurs (Graphique de gauche), enrichie par la médiane de risque.
Sur le premier graphique on voit que la densité du nuage de points s'affaisse vers le bas à mesure que l'engagement augmente : un fort engagement tire mathématiquement le risque de churn vers le bas.
Le deuxième graphique se concentre sur la zone la plus dense (scores d'engagement de 0 à 250). L'ajout de la ligne de démarcation (médiane du Churn) révèle deux profils atypiques et cruciaux :

- Les utilisateurs qui présentent un engagement quasi nul mais un risque de départ inférieur à la médiane. Cela représente les visites ponctuelles, utilitaires ou encore de potentiels oublis de résiliation d'abonnement. (en bas à gauche, 1er graphique)
- Les utilisateurs très engagés mais dont le risque de churn explose. Ce sont des abonnés qui utilisent énormément l'application mais qui sont tout de même fortement susceptibles de la quitter. (en haut à droite, 2e graphique)

Ces visualisations illustrent un paradoxe : un fort niveau d'engagement ne se traduit pas automatiquement par une rétention assurée. Le péril majeur pour l'entreprise réside chez les utilisateurs très engagés, des utilisateurs très présents mais au bord du départ. Cette situation met en lumière de sévères défauts dans l'expérience proposée (bugs, limites frustrantes du modèle gratuit ou fatigue face à la publicité).

3. Diagramme en violon du nombre de vidéos vues par tranche d'âge

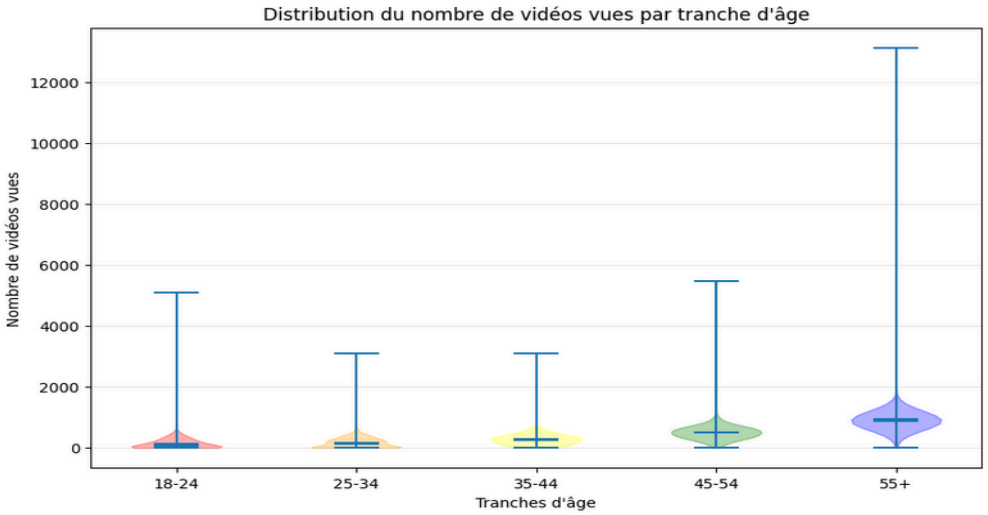

Le nombre de vidéos vues est l'un des indicateurs d'engagement le plus pertinent sur une plateforme sociale. C'est pourquoi nous avons choisi de visualiser l'engagement des différentes tranches d'âges à travers un diagramme en violon du nombre de vidéos vues par catégories d'âges. Montrant à la fois la distribution complète des données, leurs statistiques clés et permettant une comparaison visuelle claire entre plusieurs groupes, le diagramme en violon est la représentation idéale pour effectuer une analyse des vidéos vues en fonction de l'âge.

Et en effet, nous observons chez les 18-24 ans une distribution très concentrée sur les valeurs faibles, presque semblable à celle des 24-34 ans, ce qui implique un nombre de vidéos vues peu important. Une légère augmentation se fait voir chez les 35-44 ans même si le violon reste assez resserré. C'est chez les 45-54 ans que la transition commence à se faire avec la médiane du nombre de vidéos vues qui est plus élevée. Ici les plus de 55 ans sont la population la plus intéressante: ils ont la médiane la plus élevée, la meilleure dispersion avec le violon le plus large et la plus haute avec certains utilisateurs qui ont visionné plus de 12000 vidéos.

Ce diagramme en violon révèle une inversion classique des usages : contrairement à l'idée reçue que « les jeunes regardent tout le temps des vidéos », ce sont ici les utilisateurs les plus âgés (55+) qui sont les plus gros consommateurs de vidéos.

4. Un p’tit truc en plus !

Deux variables n’ayant à priori pas de pertinence avec les autres données ont été repérées: geo_lat et geo_long. Donnant les coordonnées GPS des utilisateurs, on a voulu voir ce que donnerait un nuage de points fait avec ces informations. Et nous avons obtenu une surprise de niveau!

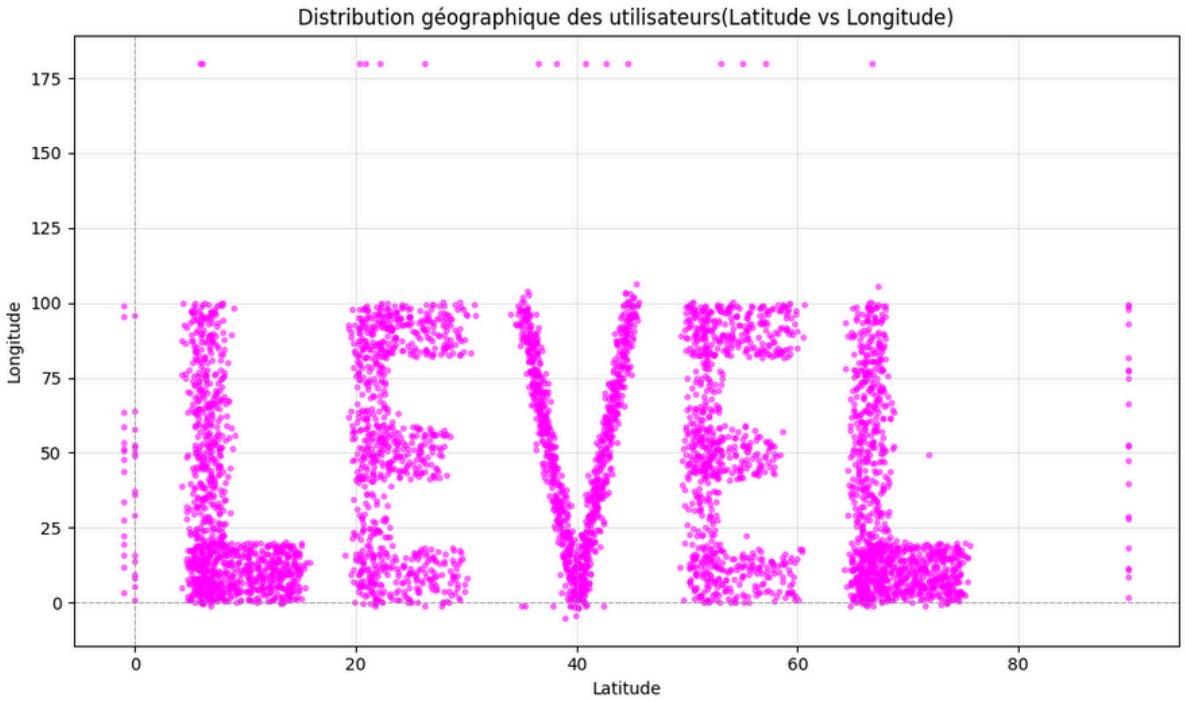

Pour conclure, ce dataset nous a montré que les comportements des utilisateurs sont souvent à l'opposé de ce qu'on imagine. Les plus engagés ne sont pas forcément les plus fidèles, et ce sont les seniors qui regardent le plus de vidéos. Autant de résultats qui mériteraient d'être creusés davantage, notamment en croisant davantage les variables entre elles.

IV - Auto Evaluation

Au vu du barème et des critères de rédaction du rapport, nous nous attribuons la note de **10/14**.

En effet, nous considérons que notre travail respecte la majorité des clefs de la grille critérié. Cependant, nous n’avons pas explicité la méthodologie adoptée pour le travail collectif. Toutes les données, bien qu’ayant été comprises, n’ont pas été interprétées dans leur caractère unidimensionnel. Néanmoins notre stratégie de nettoyage des données a été pertinente et efficace, nos choix de visualisations reposent sur des questionnements auxquels une analyse approfondie a permis de répondre et nous avons fait de notre mieux pour exploiter le dataset de manière originale.

Rapport fait par : *Nassim BERRABAH, Aiissatou WADE, Sara YOUNGA*